Breast Cancer

Diagnostic Analysis

Machine Learning Pipeline per la Classificazione di Tumori al Seno (Maligno / Benigno)

569	30	63/37
Campioni	Features	B/M Ratio

UCI ML Repository — Breast Cancer Wisconsin (Diagnostic)

Pipeline del Progetto

01

Caricamento Dati

Dataset UCI — 569 campioni, 30 features, target binario Maligno/Benigno

02

EDA & Visualizzazione

Statistiche descrittive, boxplot, pairplot, analisi delle correlazioni

03

Preprocessing

Standardizzazione (StandardScaler), encoding target, feature selection

04

Modellazione

Logistic Regression + Random Forest con StratifiedKFold (5-fold CV)

05

Valutazione & XAI

Accuracy, Recall, Precision, F1 — SHAP values per interpretabilità

Il Dataset

Fonte

UCI ML Repository — Breast Cancer Wisconsin (Diagnostic)

Campioni

569 pazienti (357 Benigni + 212 Maligni)

Features

30 (mean, standard error, worst × 10 misurazioni)

Target

Diagnosi: Maligno (M) / Benigno (B)

Distribuzione Classi:

Benigno 62.7%	Maligno 37.3%

10 Misurazioni di Base

- radius · texture · perimeter
- area · smoothness
- compactness · concavity
- concave_points · symmetry
- fractal_dimension

× 3 → mean | standard error | worst

Tumore al seno

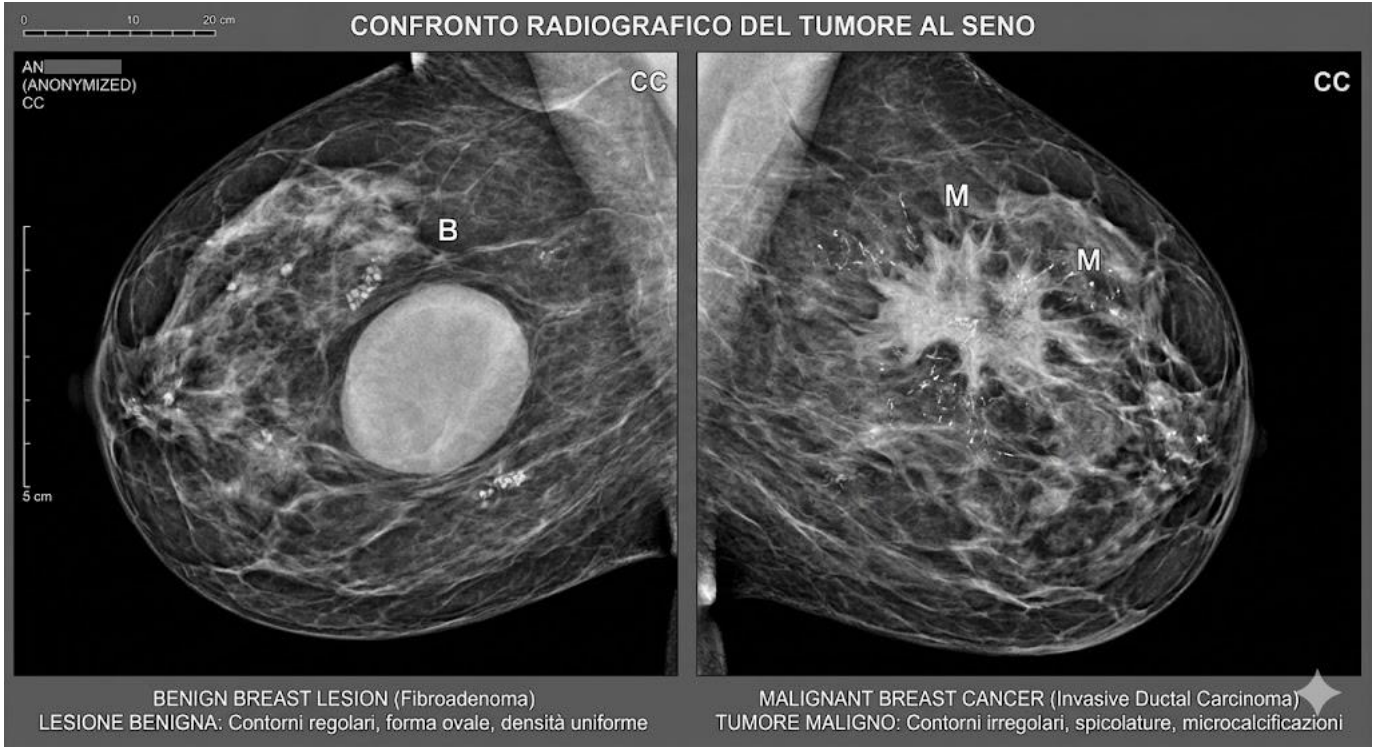

Exploratory Data Analysis

✓ Nessun Valore Mancante

Tutti i 569 campioni sono completi — il dataset è pulito e non richiede imputation.

↗ Separazione Visiva

radius_worst, perimeter_worst e concave_points_worst mostrano una netta separazione B/M nei boxplot. Un modello lineare può funzionare bene.

⚠ Problema di Scala

Le features variano enormemente: smoothness_mean ≈ 0.1 mentre area_worst arriva a 4254. La standardizzazione è obbligatoria prima di SVM/KNN.

~ Lieve Sbilanciamento

63% Benigno vs 37% Maligno. Non severo, ma richiede class_weight='balanced' e priorità al Recall invece dell'Accuracy.

Data Visualization

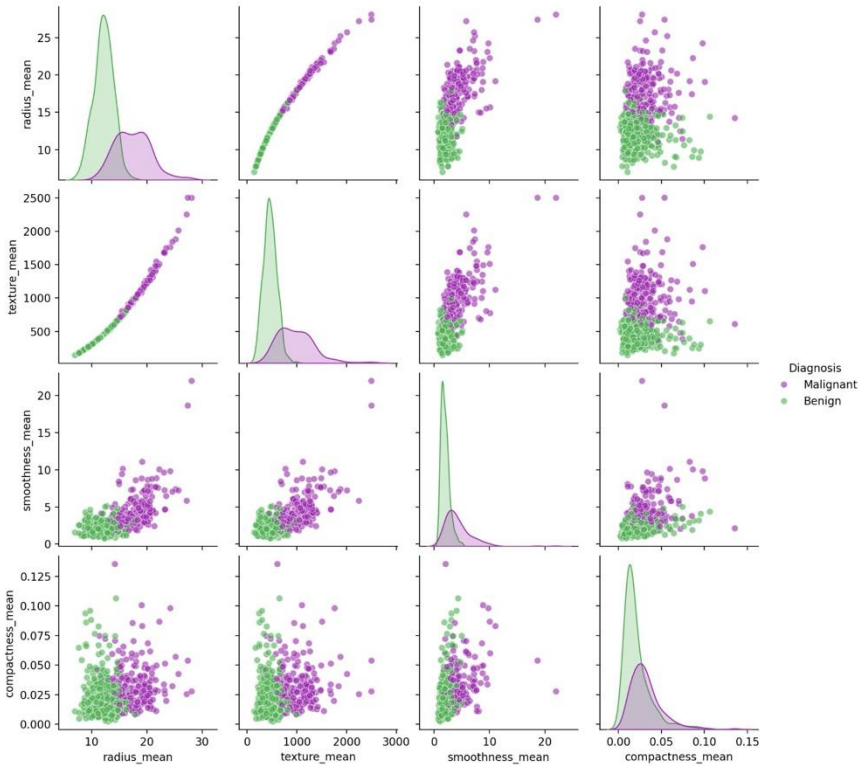

Verde: Benign (Tumori benigni) | Viola/Porpora: Malignant (Tumori maligni)

Queste distribuzioni mostrano come le features (radius, texture, smoothness, compactness) permettono una buona separazione tra le due classi

Preprocessing & Feature Selection

StandardScaler

Normalizzazione di tutte le 30 features (μ=0, σ=1).
Fondamentale per LR e SVM.

→

Encoding Target

B → 0 | M → 1
Conversione da stringa a intero per sklearn.

→

L1 Regularization

LogisticRegression(penalty='l1', C=0.05)
Identifica le 5 features più importanti azzerando le altre.

→

Top 5 Features

concave_points_worst · area_worst
radius_worst · perimeter_worst · concavity_mean

Feature Importance (L1 Logistic Regression — peso assoluto)

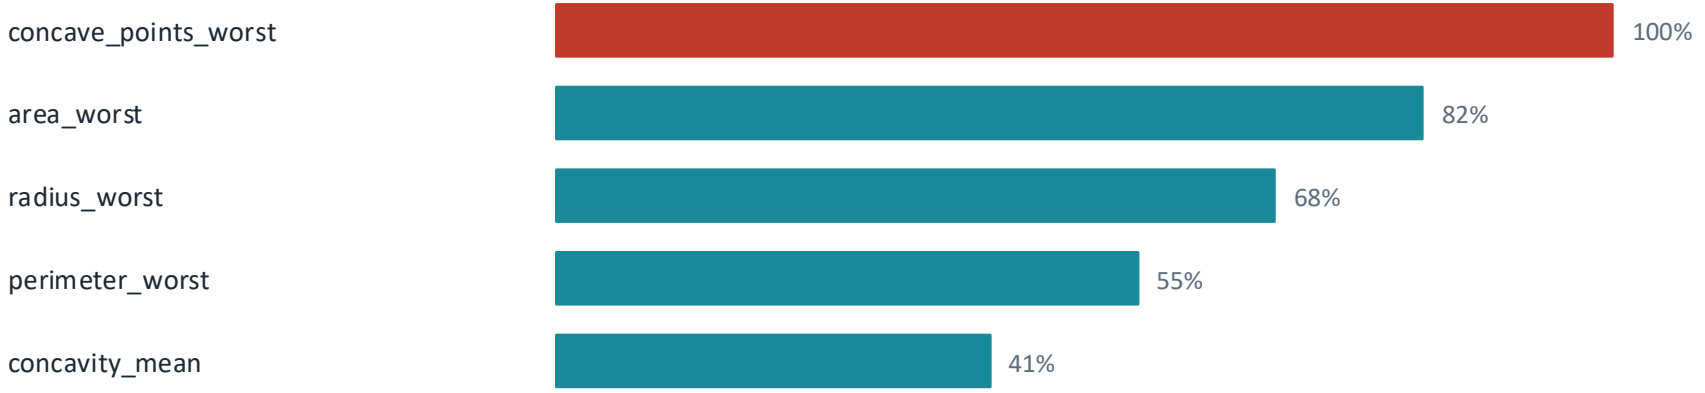

Modellazione e Valutazione

Logistic Regression (0.5)

- penalty=None, class_weight='balanced'
- StratifiedKFold (5-fold)

~94.38%	~93.42%	~92.47%
Accuracy	Recall	Precision

💡 Threshold lasciata al livello 0.5 secondo regola classificatore di Bayes

Logistic Regression (0.2)

- penalty=None, class_weight='balanced'
- StratifiedKFold (5-fold)

~92.80%	~98.13%	~85.07%
Accuracy	Recall	Precision

💡 Threshold abbassato a 0.2 per massimizzare il Recall (evitare falsi negativi)

Modellazione e Valutazione

Random Forest

- n_estimators=100, class_weight='balanced'
- StratifiedKFold (5-fold), top 5 features

~93.85%	~90.11%	~93.35%
Accuracy	Recall	Precision

💡 Feature importance intrinseca — non richiede standardizzazione

Explainable AI (XAI)

Odds Ratios — Logistic Regression

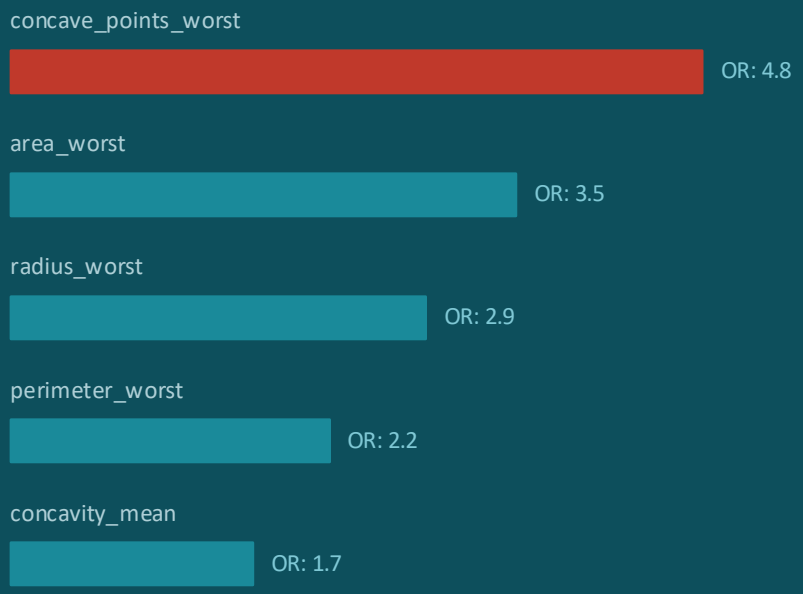

Valori > 1 indicano aumento del rischio di Malignità per ogni +1σ nella feature

SHAP Values — Random Forest

concave_points_worst
Altissimo ↑ Maligno

area_worst
Alto ↑ Maligno

radius_worst
Medio-alto ↑ Maligno

perimeter_worst
Medio ↑ Maligno

concavity_mean
Basso ↑ Maligno

Valori alti (rossi) delle features spingono la previsione verso Malignità.
Biologicamente coerente: nuclei più grandi e irregolari = segnale di malignità.

Conclusioni

Performance Elevata

Entrambi i modelli raggiungono >93% accuracy con sole 5 features su 30 — riduzione del 83% della dimensionalità senza perdita significativa di performance.

Recall > Accuracy

In contesti clinici, un Falso Negativo (paziente malato dichiarato sano) è molto più pericoloso di un Falso Positivo. Il modello prioritizza il Recall.

XAI e Interpretabilità

SHAP values confermano che concave_points_worst e area_worst sono i biomarker più rilevanti — coerente con la letteratura oncologica.